


孙圣杰

男 | 年龄：27岁 | 籍贯：无锡 | 共产党员 | 19906154505 | 864293718@qq.com

求职意向：大模型算法工程师 | 期望城市：上海



工作经历

思必驰科技股份有限公司 大模型算法工程师

2024.07-至今

内容:

- 持续追踪大模型领域前沿论文，深入分析其核心原理、优势劣势及适用场景。
- 负责公司业务相关大模型的全流程工作：包括使用 DeepSpeed、Megatron-LM、LlamaFactory、MindSpeed-LLM（昇腾）等大规模分布式训练框架进行模型训练，并利用 vLLM、SGLang、Imdeploy、MindIE（昇腾）等框架进行高效部署。
- 深入理解上述框架的核心设计理念与最佳实践。

业绩:

- 自研DFM系列模型（江苏省首个双备案模型）和中枢模型（控标关键点）优化。
- 显著提升团队研发效率，其贡献获得团队认可，并助力团队于2024年荣获“优秀研发团队奖”。
- 主导解决IOV部门关键技术挑战，通过算法优化项目有效推动关键里程碑达成，获得部门书面致谢。

项目经历

车载中枢大模型

2024.07-2026.03

内容:

- 在中枢大模型项目中，主导了多版本迭代过程，通过精细优化训练数据集，成功实现了43%的数据缩减，同时针对回流数据和修复反馈bug，持续提升各领域提示词及训练数据的质量，有效支撑业务需求，包括模型的训练、测试、更新及上线流程。
- 负责构建和维护高可靠性的中枢大模型数据框架，通过对现有数据实施创新的数据扩增策略，并结合SFT/DPO/GRPO算法，显著提升了各项任务的性能指标。
- 主导开发了REACT中文训练集，显著增强了模型的Function Call能力，并成功实现了包括长记忆功能、敏感词检测、指代改写、用户错字纠正、动态拼字拼句、高噪声指令提取及复杂拒识在内的多项关键功能，为模型的实用性和准确性做出了重大贡献。
- 针对特定任务采用多语种数据蒸馏方法，构建了多语种语料库，多语种垂域分类任务的准确率实现了50%的显著提升，为跨语言场景下的应用拓展奠定了坚实基础。
- 负责测试并实施S-Lora方案与RAG方案，有效支持了产品级自定义中枢落域功能的开发，进一步增强了产品的灵活性和用户体验。
- 进行了线上数据回流的评估与测试工作，确保数据质量与系统性能的持续优化，为项目的长期发展提供了坚实的技术保障。

业绩:

- 中枢模型各项任务业务测试组效果指标均达到95%，业内领先。
- 智慧聆听模块包含用户错字纠正、动态拼字拼句、高噪声指令提取等功能，车载领域成功量产落地，得到各车厂的好评。
- 长时记忆功能为感知决策提供支持，能够存储车主的个人信息、最近动态、喜好偏好等主观特征，为每个人特别定制服务。

DFM系列模型演进 负责人

2025.11-至今

内容:

- 基于A800百卡集群，主导DFM系列模型（7B-110B等Dense模型，235B等MoE模型）的演进与训练。
- 引入CP，SP，EP等并行化策略化和Packing策略，提升模型收敛效率。

业绩:

- 模型效率提升18%，MFU达到37%。

- 针对智能家居、车控等垂直场景，通过数据蒸馏，使小模型的Function Call能力对标235B大模型，在真实场景下准确率提升23%。

昇腾大模型训练适配/优化

2025.02-2025.03

- 内容:
1. 昇腾适配支持MindSpeed-LLM, LLaMaFactory, Deepspeed-Chat等常用训练框架，构建容器环境，适配vc调度启动方式。对14B和1.5B模型进行prefile分析，使其训练速度和精度都对齐A800，采用packing策略MFU训练指标接近在20%。

2. 基于昇腾MindIE推理框架部署DeepSeek、Qwen3-235B-A22B 等大型MOE模型，速度达到Nvidia 70%，接入大模型应用平台。

3. 大模型训练平台：基于MindSpeed-LLM适配Qwen1.5, Qwen2.5, LLaMa3.1, 零一万物, ChatGLM3, DFM等开源模型的全量参数训练脚本与Lora训练脚本；大模型训练平台采用昇腾modelslim框架支持模型W8A8量化，采用MindIE框架推理模型；以确保大数训练平台项目顺利交付。
- 业绩:
1. 为大模型训练平台提供算法支持，确保大模型训练平台顺利交付，首个交付项目达到千万级收益，并支持私有化部署，模式可快速复制。

2. 支持7B, 14B量级模型训练，MindSpeed-LLM训练效率与Nvidia LlamaFactory持平，SFT 变长序列训练任务中MFU达到近20%，单次训练成本降低一倍。通过profiler工具逐层分析隐藏层状态，发现并纠正由于attention mask导致的精度问题。

3. 迭代跟进DeepSeek在MindIE上的部署技术，与A800 vLLM推理速度对齐，仍低于SGLang。

分布式智能体研发

2025.07-至今

- 内容:
1. 实现MCPhub代理，支持多MCP服务集成，分组管理，自定义MCP工具描述，单工具禁用，Toollist缓存等功能。支持npm、uvx、sse、streamhttp、dxt等方式加载MCP。

2. 基于Prometheus + Grafana技术栈构建实时监控与告警体系。

3. 实现车控Agent，基于Function call实现车控功能，融合物模型快出，长短期记忆，车辆状态，MCP list筛选等功能。
- 业绩:
1. 接入大模型应用平台，实现Workflow, Agent, MCP等工具的混合调用。

2. 新车控Agent方案上线使用。

端侧大模型适配

2025.04-至今

- 内容:
1. 端侧芯片算力调研与开源方案性能测试：
 - 系统梳理主流端侧芯片算力（高通骁龙8295/联发科天玑MTK8678/瑞芯微RK3588/RK1820/后摩M50/英伟达Orinx AIBox），量化对比关键指标：INT4/INT8峰值算力(TOPS)、内存带宽(GB/s)、功耗限制(W)等；
 - 测试LLama.cpp和MCL-LLM在多进程条件下、绑定核数与大小核的速度。多进程大核绑定提升3.3倍吞吐，首Token延迟降低67%。

2. MTK端侧大模型推理引擎优化：
 - 基于MediaTek GenAI SDK编译LLM，启用INT4权重量化+INT16激活值混合精度。
 - 设计分段式Prefill策略：基于C++自主实现动态KV Cache管理器，将长文本拆分为<128 tokens的块分块进行前缀匹配和prefill计算。
 - 推理策略升级：对INT16 Logits反量化转换为FP16，并结合Temperature、Penalty采样丰富回答多样性。
- 业绩:
- 为车载客户输出《端侧LLM芯片选型指南》，为产品POC阶段提供技术支持。发现内存带宽为端侧推理关键瓶颈，采用混合量化策略。

- 主导会议本端侧大模型加速引擎研发，基于端侧单并发特性优化端侧会议处理流程，会议四任务整体耗时提升3.8倍：1万字会议内容处理耗时从35分钟→8分钟。在公司首款会议本设备实现端侧万字会议实时分析，响应速度超科大讯飞竞品2.7倍。
- 车载端侧大模型实现能够在0.5s内实现垂域分类、敏感词检测、指代改写、复杂车控等。闲聊回复首Token在0.7s内，支持主动打断和全时垂域免唤醒功能。在IOV车载OS量产部署，满足车载语音助手严苛的延迟要求。

专业技能

1. 代码技能：python, java, C++, typescript, lua
2. 大模型训练技术：微调(SFT), 强化学习(DPO/PPO/GRPO/GSPO)。
3. 大模型训练优化技术：熟悉llamafactory/deepspeed/swift/megatron训练框架，了解并行训练 (DP,TP,PP,SP,CPEP), FlashAttention, Zero模式, Ray, FSDP, 重计算。
4. 大模型推理加速技术：熟练sglang/vllm推理框架使用，模型量化 (GPTQ, AWQ ,QAT), KVcache 前缀缓存, Speculative Decoding (EAGLE, Lookahead, Medusa), MOE EP方案, PagedAttention。

个人优势

主动跟进大模型领域的最新进展，积极主动得在新算法上进行业务测试；
有针对性得对新算法和新产品的开源代码学习研读，持续学习提高代码规范性和方法创新性；
具有较强的自我驱动力，对任务有着明确的计划，并能独立制定和执行达成这些目标的策略；

教育经历

南京信息工程大学 硕士 计算机科学与技术 2021-2024

研究方向：自然语言处理、大语言模型、知识图谱

1. Rong H, Sun S, Ma T, et al. KGCDP-T: Interpreting knowledge graphs into text by content ordering and dynamic planning with three-level reconstruction[J]. Knowledge-Based Systems, 2024, 284: 111297.
2. 孙圣杰,马廷淮,黄凯.融合干预与反事实的知识感知型去偏推理模型[J].计算机科学与探索,2024,18(12):3288-3299
3. 马廷淮,孙圣杰,荣欢,钱敏峰.基于动态记忆和双层重构强化的知识图谱至文本转译模型[J].计算机科学,2023(3):12-22.

合作项目：

1. Li W, Li L, Lee M, et al. Adaptive layer sparsity for large language models via activation correlation assessment[J]. Advances in Neural Information Processing Systems, 2024, 37: 109350-109380.
2. Li W, Li L, Gu H, et al. MoE-SVD: Structured Mixture-of-Experts LLMs Compression via Singular Value Decomposition[C]//Forty-second International Conference on Machine Learning.
3. Li W, Li L, Lee M, et al. BayesKD: Bayesian Knowledge Distillation for Compact LLMs in Constrained Fine-tuning Scenarios[C]//Findings of the Association for Computational Linguistics: ACL 2025. 2025: 138-152.
4. Gu H, Li W, Li L, et al. Delta Decompression for MoE-based LLMs Compression[C]//Forty-second International Conference on Machine Learning.
5. Zhu Y, Ma T, Sun S, et al. RTA: A reinforcement learning-based temporal knowledge graph question answering model[J]. Neurocomputing, 2025, 617: 128994.
6. 桑晨扬,马廷淮,谢欣彤,孙圣杰,黄锐. 基于大语言模型多阶段推理的情绪支持对话生成方法 [J]. 计算机科学与探索. 2024 (11)

兴趣爱好

健身\骑行\羽毛球\壁球\登山\抱石